BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC MỎ - ĐỊA CHẤT

ĐỀ CƯƠNG ĐỒ ÁN 1

NGÀNH KHOA HỌC DỮ LIỆU

ĐỀ TÀI: XÂY DỰNG MÔ HÌNH TÓM TẮT VĂN BẢN

NHÓM THỰC HIỆN GỒM

Đỗ Văn Dũng

Mssv: 2421050055

Nguyễn Hoàng Nam

Mssv: 2421050074

Đỗ Lý Bảo

Mssv: 2421050044

GIẢNG VIÊN HƯỚNG DẪN

Gv: Nguyễn Thị Mai Dung

Hà Nội - Năm 2026

1. Lý do lựa chọn đề tài

Hiện nay lượng văn bản trong những bài báo, bài đăng trên mạng xã hội hay các nền tảng trực tuyến ngày càng lớn khiến người dùng mất rất nhiều thời gian để đọc và tìm kiếm những thông tin quan trọng.

Đặc biệt với sự phổ biến của các mô hình ngôn ngữ lớn, mô hình trí tuệ nhân tạo (AI), các văn bản được tạo ra đôi khi dài dòng, lan man và chứa nhiều thông tin không thực sự cần thiết, khiến người đọc mất nhiều thời gian để tiếp nhận và xác định nội dung chính. Tóm tắt văn bản hỗ trợ người dùng nhanh chóng nắm bắt nội dung chính của văn bản, sâu xa hơn giúp quyết định có cần đọc kỹ toàn bộ văn bản hay không.

2. Mục tiêu đề tài

Đề tài hướng đến mục tiêu xây dựng một mô hình tóm tắt văn bản bằng phương pháp trích xuất, có khả năng xác định và lựa chọn các câu chứa thông tin quan trọng từ văn bản gốc để tạo thành bản tóm tắt ngắn gọn, dễ tiếp nhận nhưng vẫn đảm bảo giữ được nội dung chính. Nhằm giải quyết vấn đề lượng văn bản lớn gây khó khăn và mất nhiều thời gian cho người đọc trong việc xác định các thông tin quan trọng, giúp người dùng nhanh chóng nắm bắt được nội dung chính của văn bản.

3. Tình hình nghiên cứu và các đề tài liên quan

Trong bối cảnh hiện nay, tình hình nghiên cứu và phát triển các mô hình tóm tắt văn bản diễn ra rất sôi nổi, đặc biệt với Tiếng Anh. Trong khi đó, các mô hình được nghiên cứu và phát triển cho ngôn ngữ Tiếng Việt lại khá hạn chế:

- PhoBERT (2003): Mô hình quy mô lớn đầu tiên được huấn luyện dành riêng cho Tiếng Việt.
- viBERT và vELECTRA (2020): Cải thiện lớn trong quá trình gán nhãn từ loại (POS Tagging) và nhận dạng thực thể có tên (NER).
- ViDeBERTa (2023): Cải thiện về biểu diễn ngữ cảnh bằng kiến trúc DeBERTaV3 mới.

- VNLawBERT (2020), ViHeathBERT (2022) và ViPubmedDeBERTa (2023): Mô hình được huấn luyện để xử lý các bài toán NLP về lĩnh vực pháp luật và y tế.

Các mô hình trên có điểm chung là đều dựa trên hướng xử lý ngôn ngữ thuật toán được phát triển như sau:

- VnCoreNLP: Bộ công cụ NLP hỗ trợ xử lý Tiếng Việt về các khâu như tách từ, gán nhãn và nhận diện thực thể có tên.
- Underthesea: Thư viện Python chuyên xử lý Tiếng Việt, cung cấp nhiều chức năng NLP và dễ tích hợp.

4. Các đóng góp của đề tài

Việc thực hiện thành công đề tài này sẽ mang lại những đóng góp cụ thể trên ba phương diện sau:

- Đóng góp về mặt thực tiễn (ứng dụng): Đề tài cung cấp một giải pháp trực tiếp giúp người dùng đối phó với tình trạng quá tải thông tin. Công cụ tóm tắt này đóng vai trò như một bộ lọc thông minh, giúp người đọc nhanh chóng nắm bắt nội dung cốt lõi của các bài báo dài hoặc các đoạn văn bản do AI sinh ra, từ đó tối ưu hóa thời gian và hỗ trợ ra quyết định có nên đọc sâu toàn bộ tài liệu hay không.
- Đóng góp về mặt kỹ thuật & công nghệ: Đề tài xây dựng thành công một quy trình (pipeline) xử lý ngôn ngữ tự nhiên hoàn chỉnh: từ bước tiền xử lý văn bản thô, tính toán trọng số/đặc trưng của câu, đến thuật toán trích xuất và tự động đánh giá mô hình bằng bộ chỉ số tiêu chuẩn ROUGE. Hơn thế nữa, với cấu trúc gọn nhẹ của phương pháp trích xuất, mô hình này hoàn toàn có tiềm năng được đóng gói và tích hợp, dễ dàng kết nối với các ứng dụng web hoặc hệ thống nội bộ mà không cần phụ thuộc vào API của bên thứ ba.
- Đóng góp về độ tin cậy của thông tin: Bằng kỹ thuật tóm tắt trích xuất, hệ thống đảm bảo duy trì tuyệt đối cấu trúc câu, văn phong và ý nghĩa gốc của tác giả. Điều này đặc biệt có giá trị đóng góp trong các lĩnh vực yêu cầu tính

chính xác cao của văn bản như tin tức báo chí, pháp lý hoặc y tế – nơi mà việc AI tự động diễn đạt lại sai lệch (hallucination) có thể gây ra hậu quả nghiêm trọng.

5. Phương pháp thực hiện

5.1 Cách tiếp cận

Đề tài tiếp cận bài toán theo hướng tóm tắt văn bản dạng trích xuất (Extractive Summarization) thay vì dạng trừu tượng (Abstractive Summarization). Cách tiếp cận này chọn trực tiếp các câu hay đoạn quan trọng từ văn bản gốc, không tạo mới hay diễn đạt lại câu chữ.

Nguồn dữ liệu đầu vào được chọn là các bộ dữ liệu mã nguồn mở, cùng với dữ liệu bổ sung từ web crawl. Sau đó tiền xử lý dữ liệu bằng bộ công cụ Underthesea, tạo tóm tắt bằng TF-IDF và TextRank. Văn bản đầu ra sẽ được đánh giá bằng chỉ số ROUGE-1, ROUGE-2 và ROUGE-L dựa trên bản tóm tắt tham chiếu.

5.2 Các bước thực hiện

Bước 1: Nghiên cứu về bài toán

Tìm hiểu về bài toán tóm tắt văn bản, các hướng tiếp cận như Abstractive và Extractive, nghiên cứu về TF-IDF, TextRank và ROUGE.

Bước 2: Thu thập và xây dựng bộ dữ liệu

Thu thập văn bản từ các bộ dữ liệu mã nguồn mở và web crawl. Kiểm tra loại bỏ dữ liệu không phù hợp để xây dựng bộ dữ liệu thực nghiệm.

Bước 3: Tiền xử lý văn bản

Làm sạch và chuẩn hoá văn bản, sử dụng thư viện Underthesea để phân tách câu và tách từ.

Bước 4: Xây dựng mô hình tóm tắt

Nghiên cứu và áp dụng TF-IDF, TextRank để xác định mối quan hệ giữa các câu và xếp hạng mức độ quan trọng.

Bước 5: Tạo văn bản tóm tắt

Lựa chọn các câu có điểm số xếp hạng cao trong văn bản đầu vào. Sau đó sắp xếp các câu được lựa chọn theo đúng thứ tự để tạo thành văn bản tóm tắt.

Bước 6: Đánh giá kết quả

So sánh mức độ tương đồng giữa bản tóm tắt được tạo ra với bản tóm tắt tham chiếu bằng các chỉ số ROUGE-1, ROUGE-2 và ROUGE-L.

Bước 7: Tổng kết

Hoàn thành báo cáo, slide thuyết trình, mã nguồn sản phẩm.

6. Kế hoạch thực hiện

Bước 1	Thời gian dự kiến: 2 tuần Sản phẩm dự kiến: Bộ dữ liệu được thu thập từ các nguồn để phục vụ xây dựng và đánh giá mô hình.
Bước 2	Thời gian dự kiến: 1 tuần Sản phẩm dự kiến: Bộ dữ liệu đã được làm sạch và xử lý.
Bước 3	Thời gian dự kiến: 2 tuần Sản phẩm dự kiến: Mô hình tóm tắt văn bản bằng phương pháp trích xuất sử dụng TF-IDF và TextRank.
Bước 4	Thời gian dự kiến: 1 tuần Sản phẩm dự kiến: Chương trình tóm tắt văn bản.
Bước 5	Thời gian dự kiến: 1 tuần. Sản phẩm dự kiến: Báo cáo đánh giá kết quả mô hình bằng các chỉ số ROUGE-1, ROUGE-2 và ROUGE-L.
Bước 6	Thời gian dự kiến: 2 tuần. Sản phẩm dự kiến: Báo cáo đồ án hoàn chỉnh, slide thuyết trình và mã nguồn sản phẩm.

7. Tài liệu tham khảo

[1] T. V. Bui, T. O. Tran and P. Le Hong, "Improving Sequence Tagging for Vietnamese Text using Transformer-based Neural Models," 2020.

[2] Q. N. Dat and T. N. Anh, "PhoBERT: Pre-trained language models for Vietnamese," 2020.

[3] C. D. Tran, N. H. Pham, A. Nguyen, T. S. Hy and T. Vu, "ViDeBERTa: A powerful pre-trained language model for Vietnamese," *arXiv preprint arXiv:2301.12788,* 2023.

[4] C. N. Chau, T. S. Nguyen and L. M. Nguyen, "VNLawBERT: A Vietnamese Legal Answer Selection Approach Using BERT Language Model," in *2020 12th International Conference on Knowledge and Systems Engineering (KSE)*, Can Tho, 2020.

[5] M. P. Nguyen , V. H. Tran, V. Hoang, T. D. Huy, T. H. Bui and S. Q. Truong, "ViHealthBERT: Pre-trained Language Models for Vietnamese in Health Text Mining," in *Proceedings of the 13th Conference on Language Resources and Evaluation (LREC 2022)*, Marseille, 2022.

[6] M. Tran-Tien, H.-L. Le, N. M. Dang, T. Tran Khang, H.-T. Vu and M.-T. Nguyen, "ViPubmedDeBERTa: A Pre-trained Model for Vietnamese Biomedical Text," in *Proceedings of the 37th Pacific Asia Conference on Language, Information and Computation (PACLIC 2023)*, PNG.

[7] T. Vu, D. Q. Nguyen, D. Q. Nguyen, M. Dras and M. Johnson, "VnCoreNLP: A Vietnamese Natural Language Processing Toolkit," in *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Demonstrations*, 2018.

[8] C.-Y. Lin, "ROUGE: A Package for Automatic Evaluation of Summaries," in *Text Summarization Branches Out: Proceedings of the ACL-04 Workshop*, 2004.

[9] R. Mihalcea and P. Tarau, "TextRank: Bringing Order into Texts," in *Proceedings of the 2004 Conference on Empirical Methods in Natural Language Processing (EMNLP 2004)*, Barcelona, Spain, 2004.