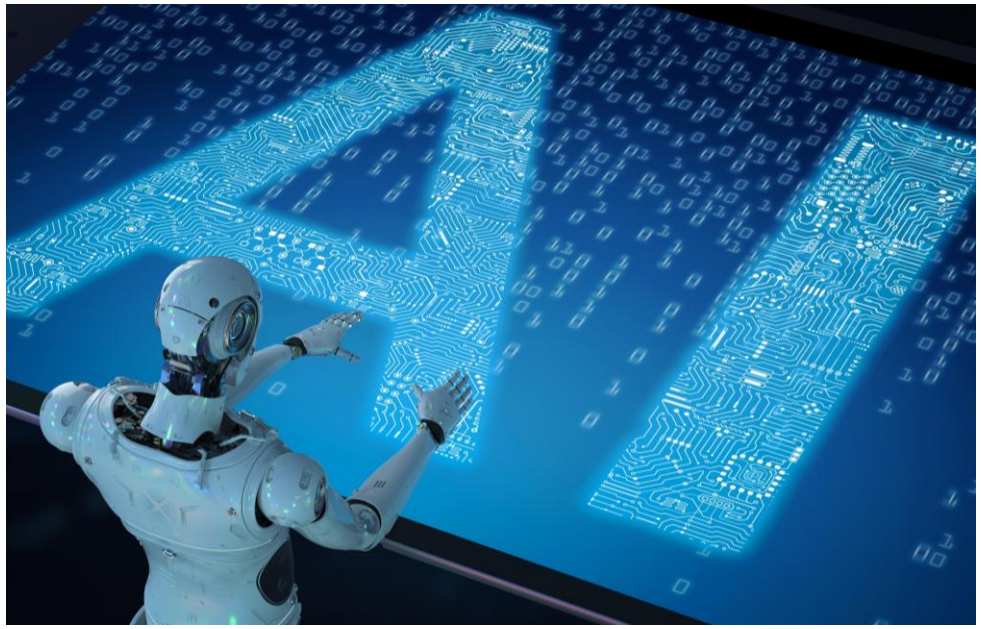
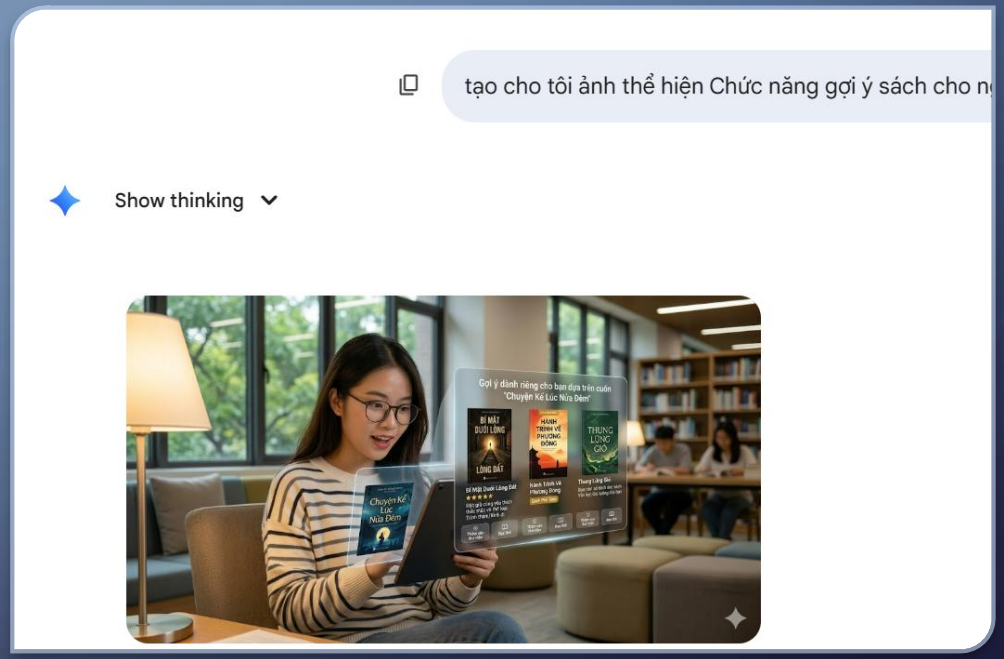
AI
KHẢ NĂNG VÀ HẠN CHẾ



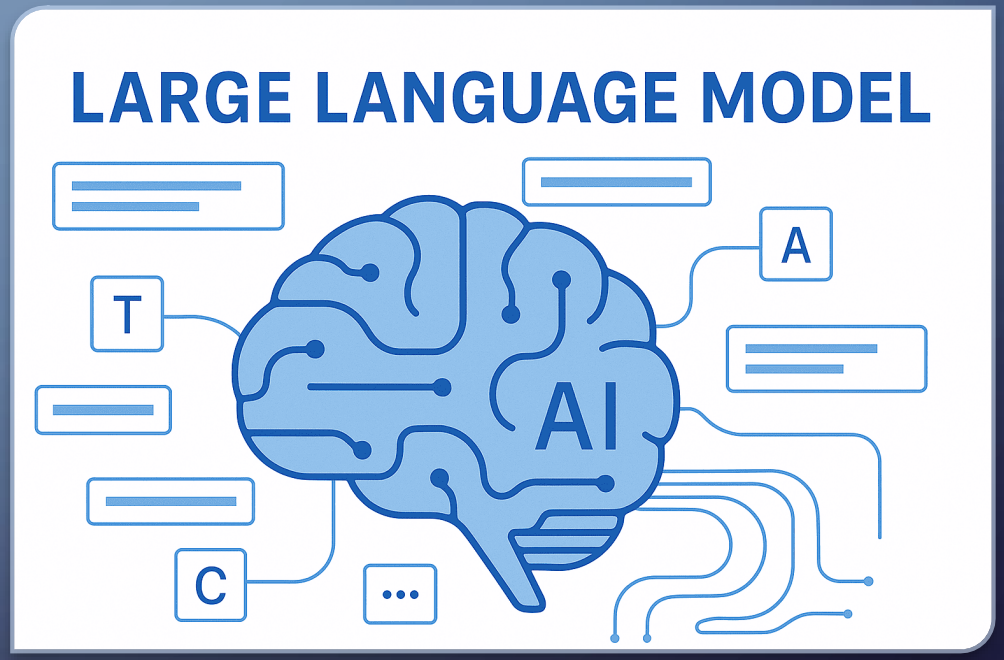
GenAI - AI TẠO SINH

- GenAI được hiểu các hệ thống trí tuệ nhân tạo có khả năng **tạo ra nội dung mới** thay vì chỉ đơn thuần phân tích dữ liệu hiện có
- GenAI cho phép tạo ra văn bản, hình ảnh, âm nhạc hay code lập trình
- GenAI được xây dựng tương tự như xây dựng các ứng dụng AI khác, tuy nhiên lượng dữ liệu được sử dụng lớn hơn rất nhiều và mô hình phức tạp hơn rất nhiều
- Dữ liệu cho GenAI được lấy từ rất nhiều nguồn khác nhau: văn bản, website, mã máy tính, hình ảnh, âm thanh, ...



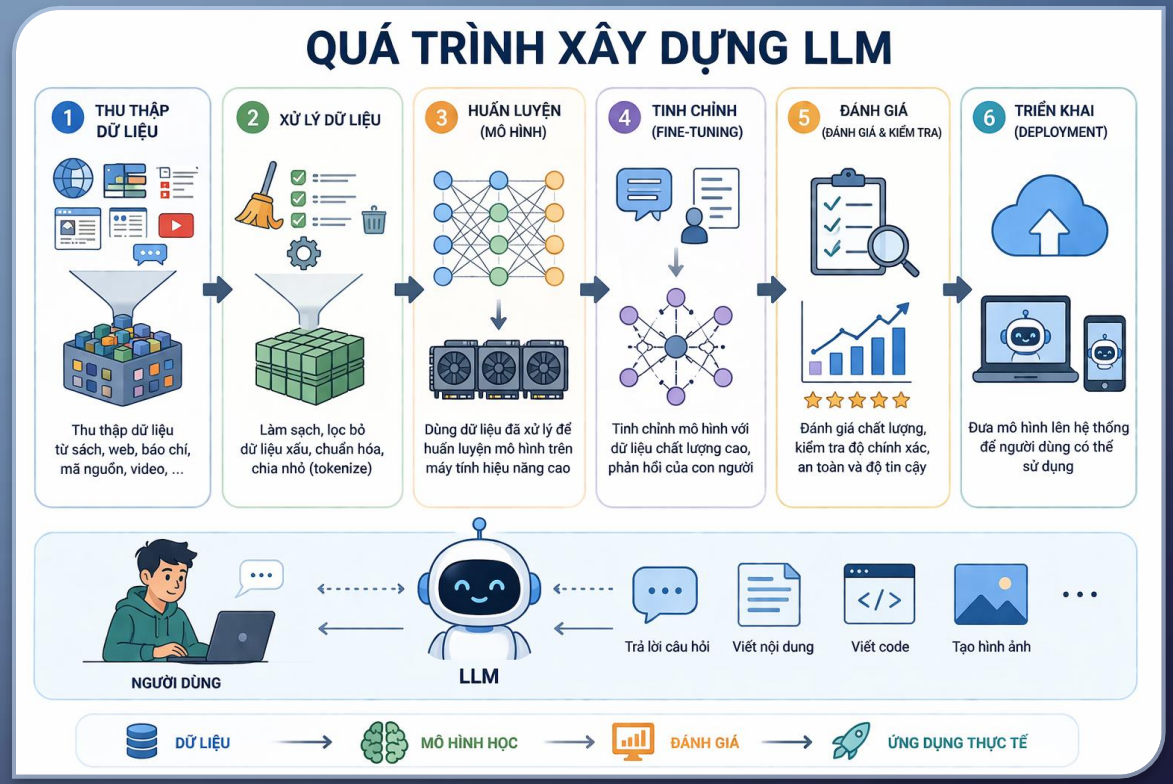
MÔ HÌNH NGÔN NGỮ LỚN (LLM)

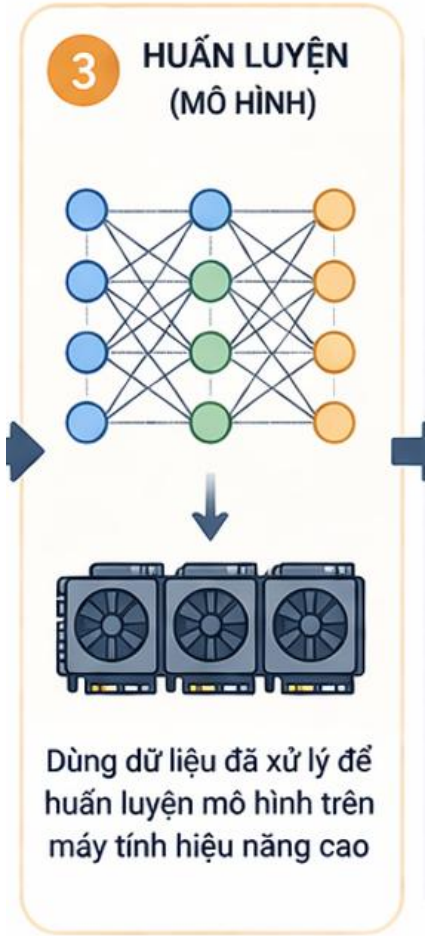
- LLM được huấn luyện để dự đoán và tạo ra ngôn ngữ của con người
- LLM được gọi là "lớn" vì chứa hàng tỷ tham số—đây là các giá trị toán học quyết định cách mô hình xử lý thông tin, tương tự như các kết nối thần kinh trong não bộ



QUÁ TRÌNH XÂY DỰNG LLM

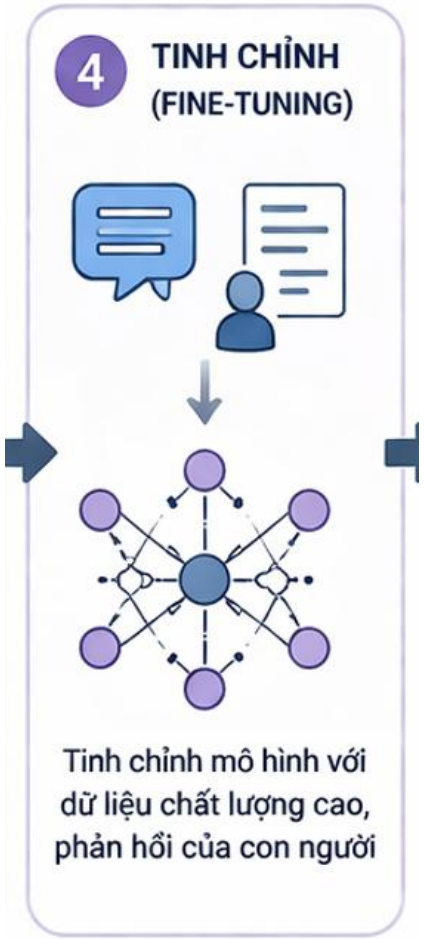
- Tiền huấn luyện (Pre-training): Mô hình phân tích hàng tỷ ví dụ văn bản để hiểu các mối quan hệ thống kê giữa các từ, cụm từ và khái niệm. Ở giai đoạn này, mô hình học cách dự đoán từ tiếp theo
- Tinh chỉnh (Fine-tuning): Mô hình được huấn luyện thêm để học cách làm theo chỉ dẫn, cung cấp câu trả lời hữu ích và tránh tạo ra nội dung sai hay có hại. Quá trình này thường bao gồm phản hồi từ con người và học tăng cường để định hình hành vi của mô hình theo hướng hữu ích, trung thực và vô hại





PRE TRAINING

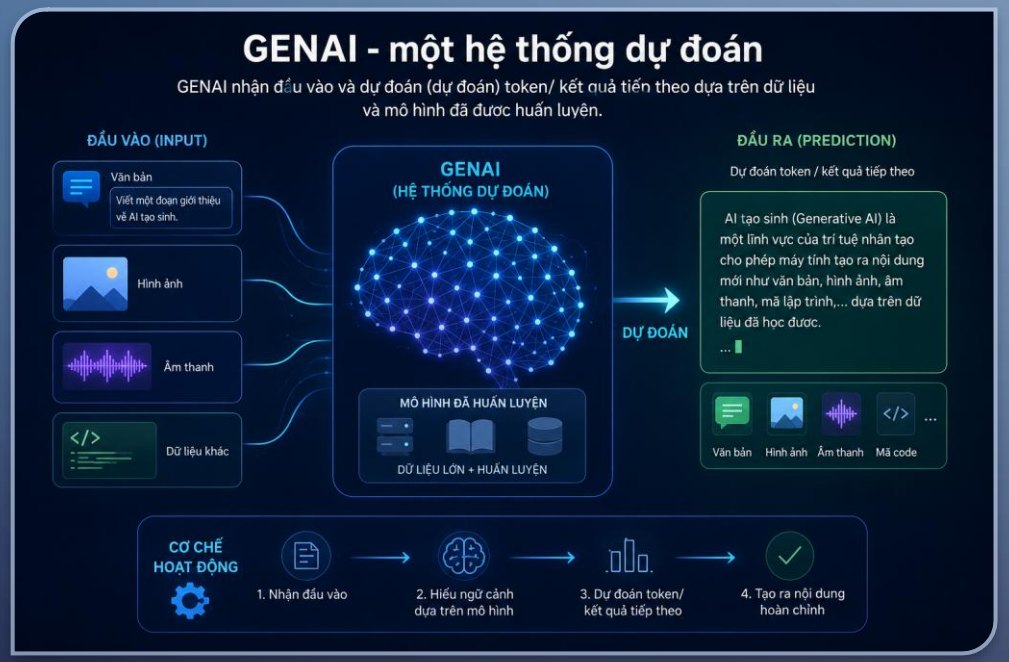
- Trong giai đoạn đầu tiên, AI được cung cấp một lượng dữ liệu khổng lồ từ sách, báo, website, tài liệu học thuật và nhiều nguồn khác.
- Nhiệm vụ duy nhất của AI lúc này là: dựa vào những gì đã xuất hiện trước đó, dự đoán từ tiếp theo là gì.
- Ví dụ: khi người dùng hỏi Thủ đô của Việt Nam? Mô hình AI ở giai đoạn này không thực sự đưa ra câu trả lời, mà tùy thuộc vào dữ liệu huấn luyện AI có thể tạo ra nội dung trả lời là "Hà Nội" hoặc tạo ra các nội dung tương tự như "thủ đô của Campuchia? Hay "thủ đô của Lào". Vì trong dữ liệu huấn luyện, nội dung thủ đô của Việt Nam thường đi với nội dung "Hà Nội" trong các bài kiểm tra. Tuy nhiên trong các tài liệu khác, câu hỏi thủ đô của Việt Nam? Lại hay đi cùng với nội dung "thủ đô của Lào?"
- Trong giai đoạn này AI không có khái niệm về người dùng, cũng không có khái niệm về việc trả lời câu hỏi. AI chỉ tiếp tục văn bản theo hướng có khả năng xuất hiện cao nhất về mặt thống kê.



FINE-TUNING

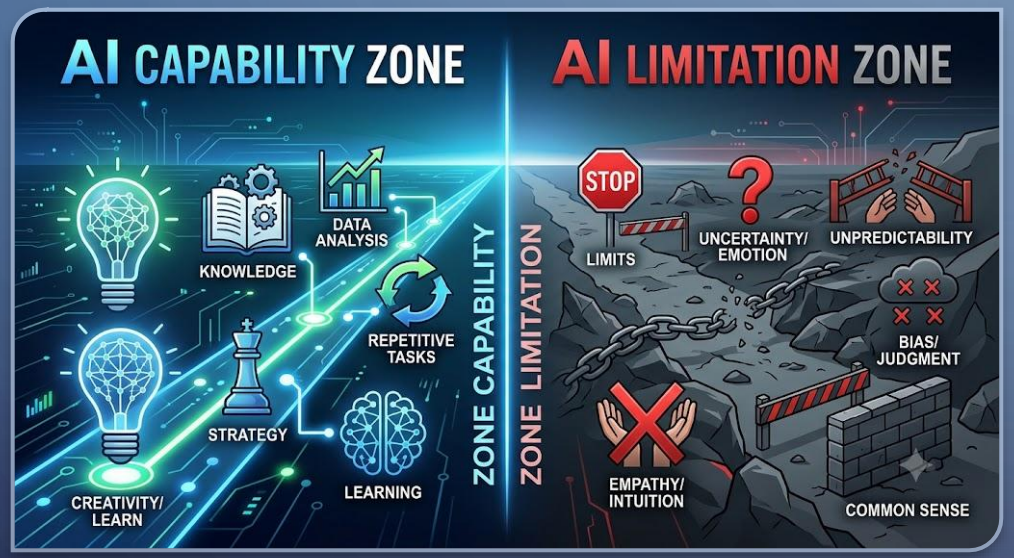
- Tinh chỉnh (Fine-tuning) là yếu tố giúp các hệ thống AI tạo sinh trở nên hữu ích và có thể sử dụng được trong thực tế.
- Tuy nhiên, vì quá trình này dựa trên đánh giá của con người về việc thế nào là một câu trả lời tốt, nên những đánh giá đó cũng để lại dấu ấn trong "tính cách" của mô hình.
- Trong nhiều trường hợp, chính những đặc điểm này khiến AI trở nên hiệu quả. Nhưng mặt khác, sự hữu ích của AI cũng có những mặt trái.

GENAI - MỘT HỆ THỐNG DỰ ĐOÁN



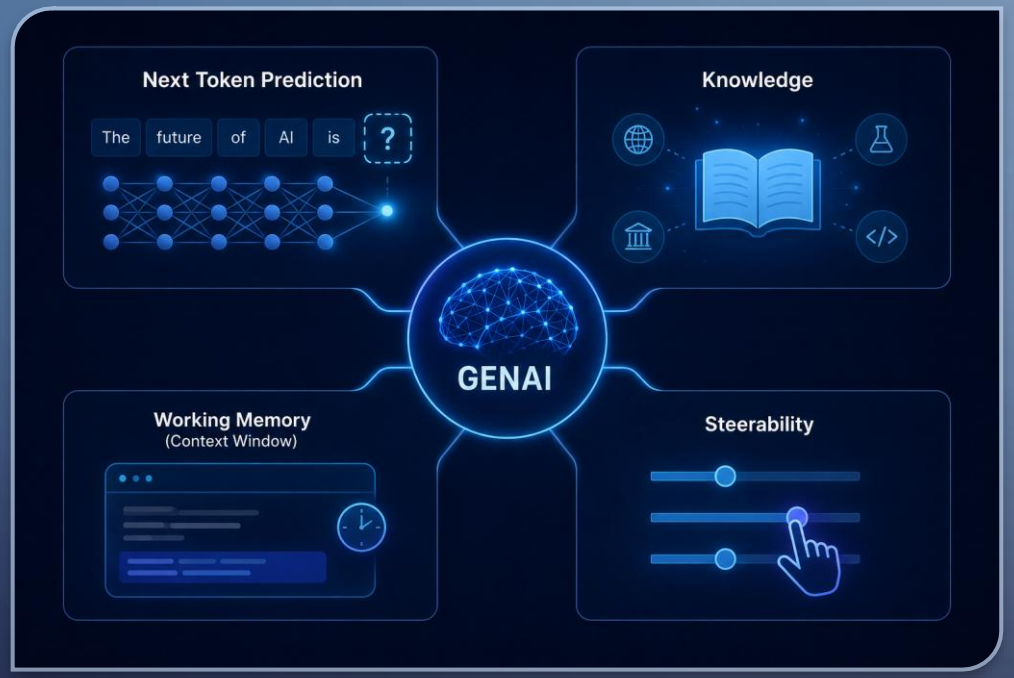
- Về bản chất AI tạo sinh là một hệ thống dự đoán.
- AI không phải giỏi mọi thứ. Nhưng cũng không phải lúc nào cũng không đáng tin.
- AI có những điểm mạnh và điểm yếu rất cụ thể, và các điểm đó thường có thể dự đoán trước được.

CAPABILITY ZONE VS LIMITATION ZONE



- Trong hầu hết các trường hợp, điểm mạnh và điểm yếu của AI lại xuất phát từ cùng một đặc tính.
- Ví dụ: AI có thể viết rất thuyết phục vì nó là một cỗ máy dự đoán, AI cũng có thể tạo ra thông tin sai (hallucination) vì nó là một cỗ máy dự đoán.
- Nếu việc được giao nằm ở **Capability Zone (Vùng năng lực) thì AI sẽ cho kết quả tốt**
- Nếu việc được giao nằm ở **Limitation Zone (Vùng giới hạn) thì kết quả từ AI sẽ không tốt**

4 ĐẶC TÍNH CỐT LÕI CỦA AI TẠO SINH



- Next Token Prediction (Dự đoán Token Tiếp Theo)
- Knowledge (Kiến thức)
- Working Memory (Bộ nhớ làm việc) – Context Window
- Steerability (Khả năng điều khiển)

NEXT TOKEN PREDICTION (DỰ ĐOÁN TOKEN TIẾP THEO)



- Đây là đặc tính cốt lõi quyết định cách các hệ thống AI tạo ra câu trả lời.
- Đây cũng là đặc tính quyết định việc AI có thể tạo ra cả những đoạn văn trôi chảy lẫn những thông tin bịa đặt
- Cốt lõi của các hệ thống AI tạo sinh là sự dự đoán, tự nội dung hiện tại, AI sẽ dự đoán nội dung sẽ suất hiện kế tiếp
- AI tạo sinh không thực sự "biết câu trả lời" theo cách con người thường nghĩ. Nó đang tạo ra câu trả lời bằng cách xây dựng từng từ, từng cụm từ dựa trên những gì thường xuất hiện tiếp theo trong dữ liệu mà nó đã học.
- AI giống với một hệ thống tự động hoàn thành văn bản (autocomplete) cực kỳ tinh vi

VÍ DỤ VỀ NEXT TOKEN PREDICTION DỮ LIỆU

- "tôi nghĩ chúng ta nên gửi báo cáo"
- "tôi thấy điều đó rất tốt"
- "tôi nghĩ chúng ta nên chờ thêm"

TÁCH CÁC TỪ LẶP LIÊN TIẾP

Câu 1

tôi → nghĩ
nghĩ → chúng
chúng → ta
ta → nên
nên → gửi
gửi → báo cáo
báo cáo → hôm nay

Câu 2

tôi → nghĩ
nghĩ → chúng
chúng → ta
ta → nên
nên → hoàn thành
hoàn thành → bài tập
bài tập → hôm nay

Câu 3

tôi → nghĩ
nghĩ → chúng
chúng → ta
ta → nên
nên → gửi
gửi → bài tập
bài tập → ngày mai

ĐẾM SỐ LẦN SUẤT HIỆN

Từ hiện tại	Từ tiếp theo	Số lần xuất hiện
tôi	nghĩ	3
nghĩ	chúng	3
chúng	ta	3
ta	nên	3
nên	gửi	2
nên	hoàn thành	1
gửi	báo cáo	1
gửi	bài tập	1
hoàn thành	bài tập	1
báo cáo	hôm nay	1
bài tập	hôm nay	1
bài tập	ngày mai	1

TRANSITION MATRIX

→	tôi	nghĩ	chúng	ta	nên	gửi	hoàn thành	báo cáo	bài tập	hôm nay	ngày mai
tôi		3									
nghĩ			3								
chúng				3							
ta					3						
nên						2	1				
gửi								1	1		
hoàn thành									1		
báo cáo										1	
bài tập										1	1

NEXT TOKEN PREDICTION

- Giả sử mô hình bắt đầu với từ **"tôi"**.
- Từ ma trận, mô hình lần lượt dự đoán: tôi → nghĩ → chúng → ta → nên
- Đến từ **"nên"**, mô hình thấy:
  - gửi (2 lần) ~ 66,6%
  - hoàn thành (1 lần) ~ 33,6%
- Lúc này tùy thuộc vào phương pháp lựa chọn từ tiếp theo, AI sẽ có thể đưa ra 2 đáp án:
  - Tôi nghĩ chúng ta nên gửi
  - Tôi nghĩ chúng ta nên hoàn thành

→	tôi	nghĩ	chúng	ta	nên	gửi
tôi		3				
nghĩ			3			
chúng				3		
ta					3	
nên						2
gửi						
hoàn thành						

SAMPLING

- **Các kỹ thuật lấy mẫu (Sampling techniques)** kiểm soát cách các mô hình ngôn ngữ lựa chọn từ tiếp theo trong quá trình sinh văn bản.
- Mô hình gán một xác suất cho mỗi từ có thể xuất hiện tiếp theo, và kỹ thuật lấy mẫu sẽ quyết định từ nào được chọn.
- Bằng cách điều chỉnh các phương pháp này, chúng ta có thể cân bằng giữa **tính sáng tạo** và **độ chính xác** của nội dung được tạo ra.

3 PHƯƠNG PHÁP SAMPLING PHỔ BIẾN



TEMPERATURE SAMPLING



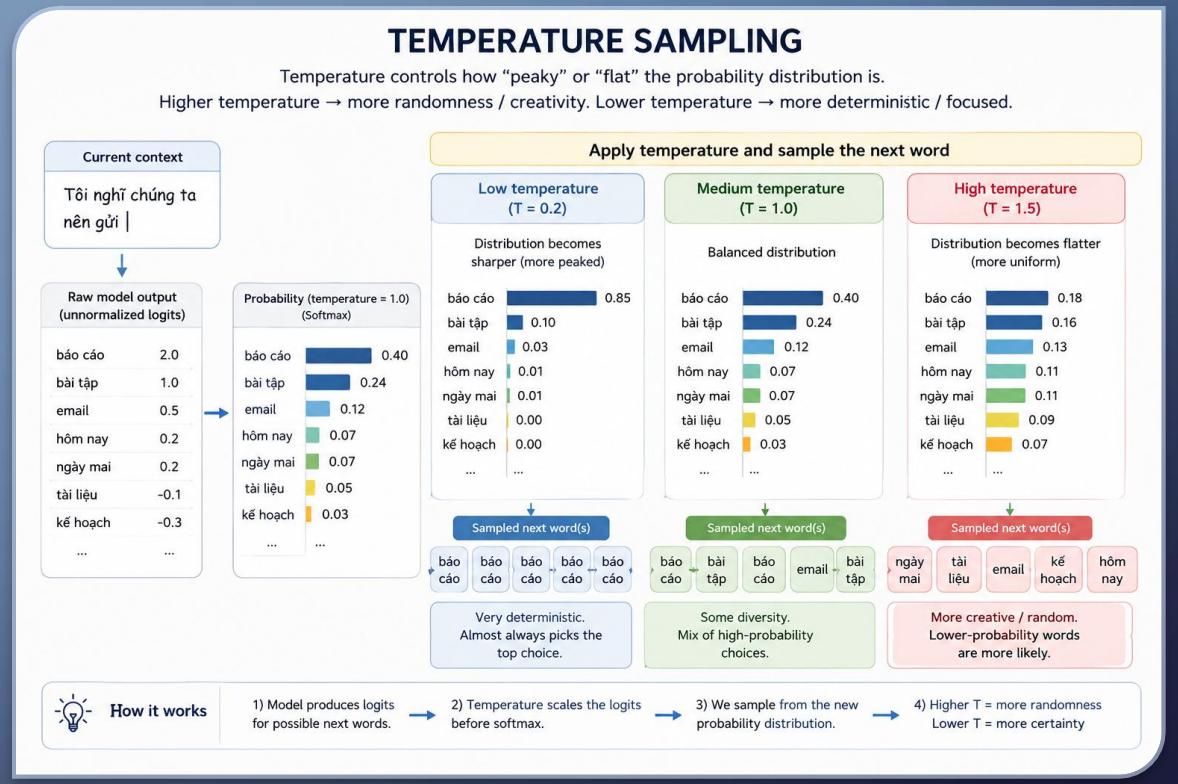
TOP K



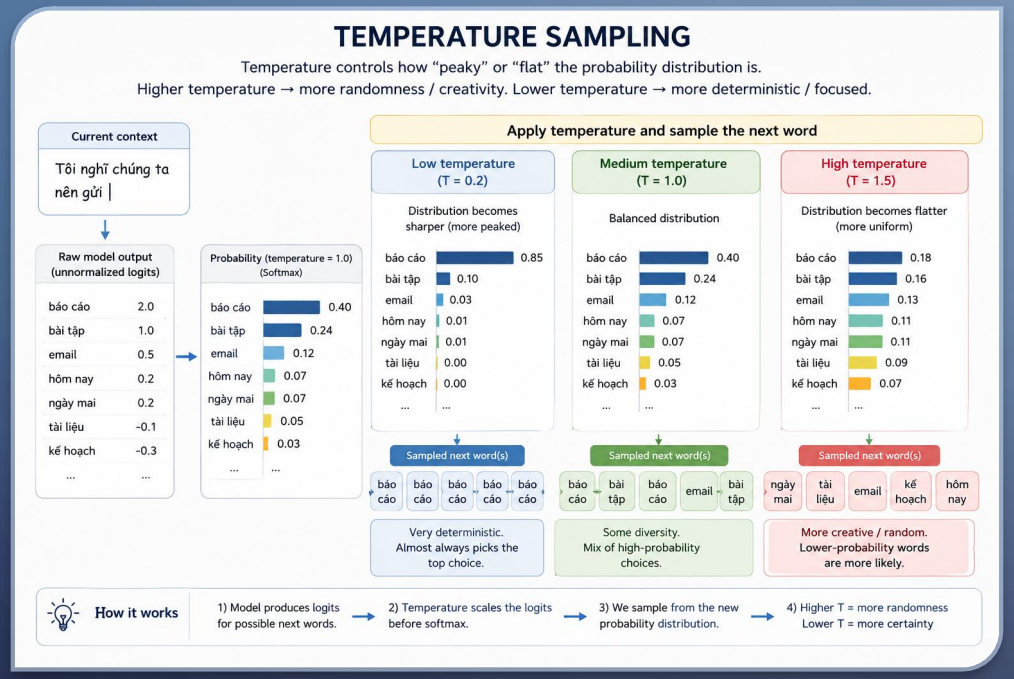
TOP P

TEMPERATURE SAMPLING

- Temperature là một tham số dùng để điều chỉnh độ "mềm" hoặc "gắt" của phân phối xác suất.
- Khi temperature thấp, mô hình sẽ ưu tiên mạnh hơn các token có xác suất cao, làm cho văn bản ổn định và ít ngẫu nhiên hơn
- Khi temperature cao, phân phối xác suất trở nên đều hơn, khiến mô hình có nhiều khả năng chọn các token ít phổ biến hơn.



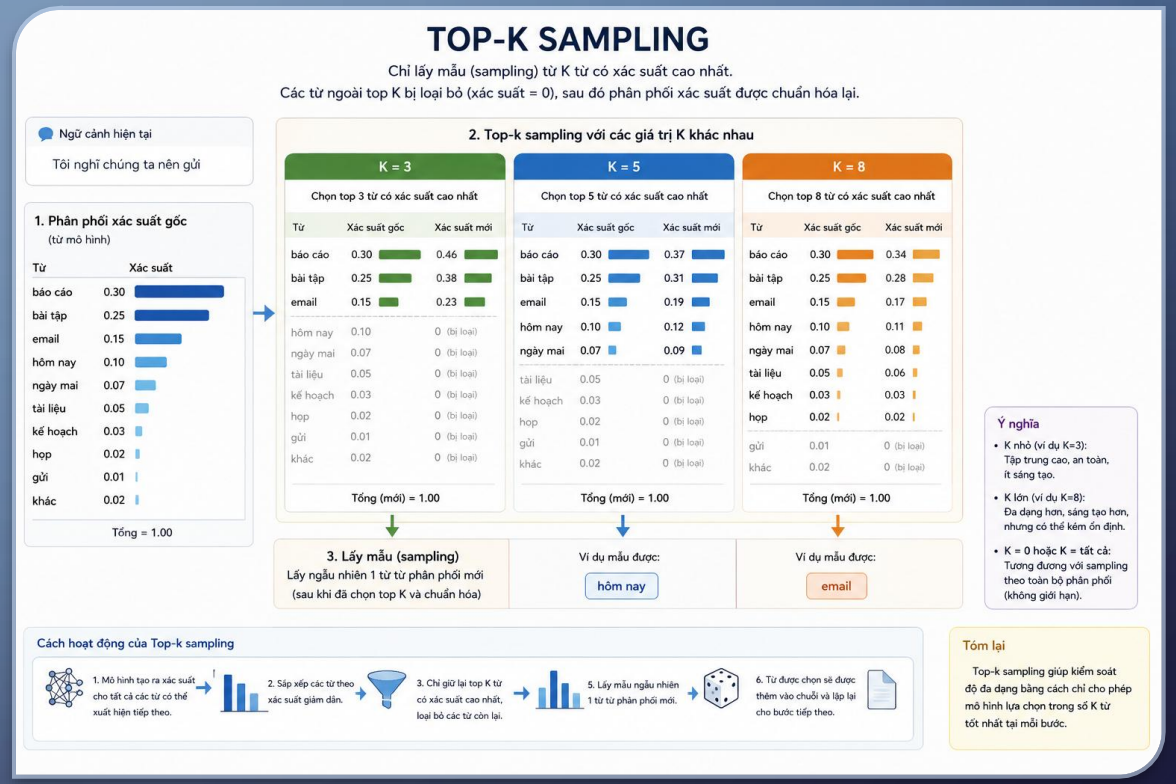
ĐIỀU CHỈNH HỆ SỐ TEMPERATURE



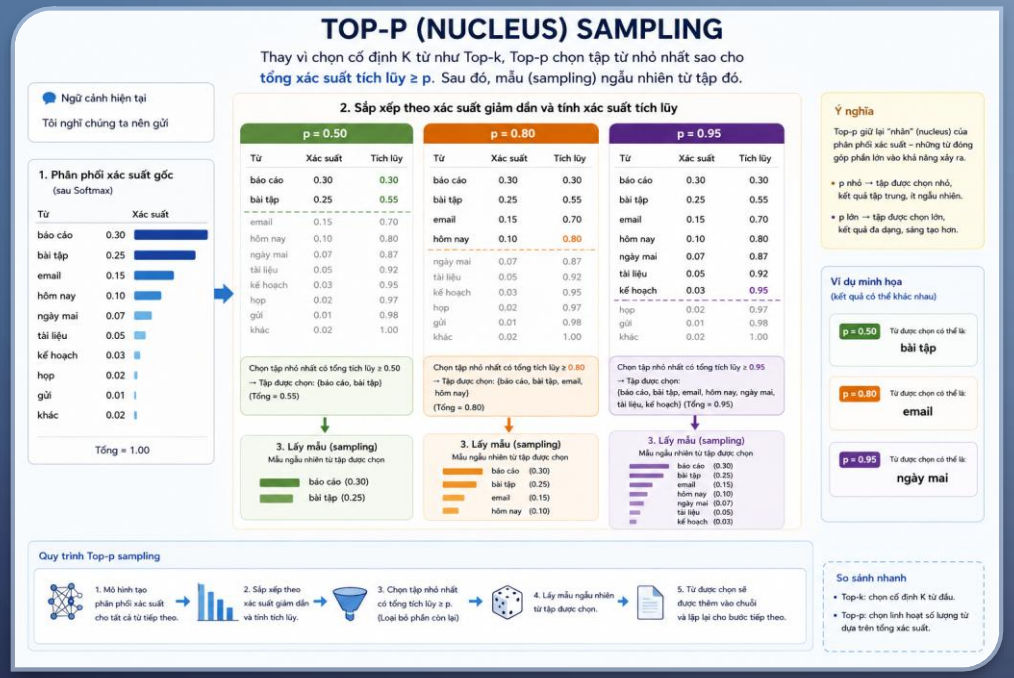
- Các mô hình AI hiện nay tự động lựa chọn chiến lược lấy mẫu phù hợp nhằm cân bằng giữa chất lượng, tính ổn định và khả năng sáng tạo của phản hồi.
- Tham số này vẫn có thể được cấu hình trong một số API hoặc nền tảng dành cho nhà phát triển, tùy thuộc vào mô hình được sử dụng.

TOP-K

- Top-k sampling là kỹ thuật giới hạn việc lấy mẫu trong k token có xác suất cao nhất. Ví dụ, nếu k = 5, mô hình chỉ chọn ngẫu nhiên trong 5 token có xác suất cao nhất và bỏ qua toàn bộ các token còn lại.
- Ưu điểm: giảm nguy cơ chọn phải các token quá hiếm hoặc không phù hợp, đồng thời vẫn giữ được tính đa dạng nhất định.
- Hạn chế: giá trị k cố định có thể không phù hợp với mọi ngữ cảnh. Có những trường hợp chỉ vài token là hợp lý, nhưng cũng có trường hợp cần nhiều lựa chọn hơn để tạo ra văn bản tự nhiên.

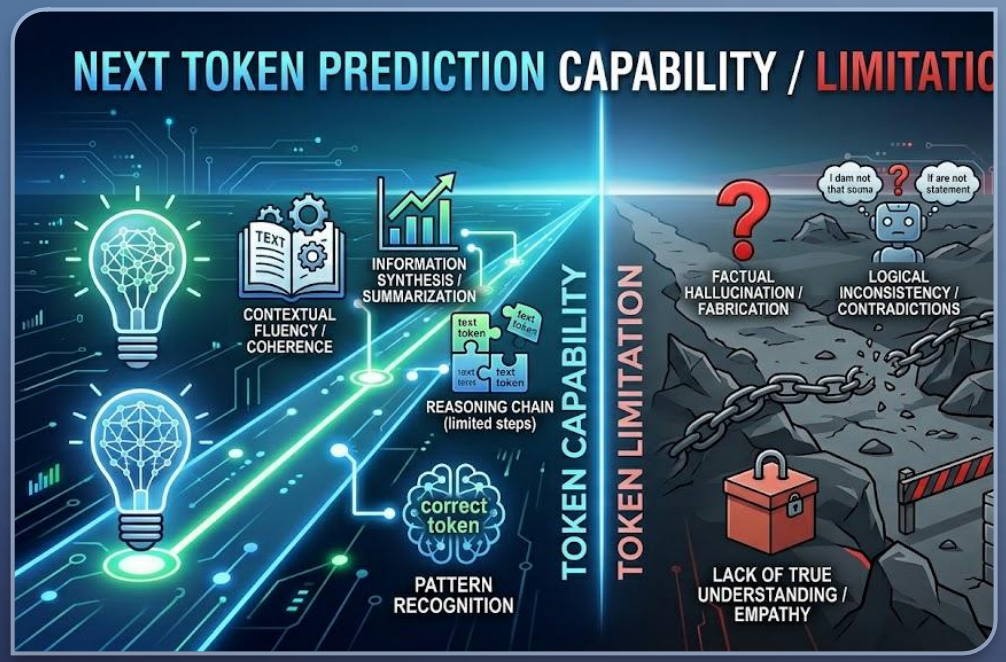


TOP-P



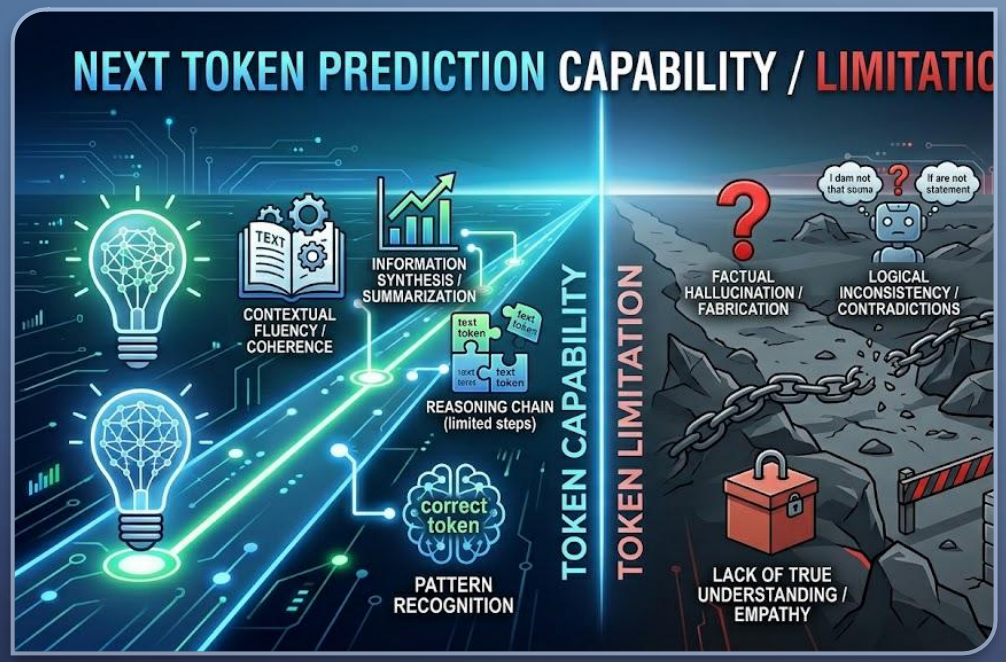
- Top-p sampling chọn tập token nhỏ nhất sao cho tổng xác suất của chúng đạt đến một ngưỡng p nhất định, ví dụ p = 0,9.
- Ưu điểm: của top-p là linh hoạt hơn top-k. Khi mô hình rất chắc chắn, tập token được chọn có thể nhỏ. Khi mô hình không chắc chắn, tập token có thể mở rộng để bao gồm nhiều khả năng hơn. Nhờ đó, top-p sampling thường tạo ra văn bản tự nhiên, đa dạng và ít bị cứng nhắc hơn.
- Top-p là một trong những kỹ thuật được sử dụng phổ biến trong các hệ thống sinh văn bản hiện đại, đặc biệt khi cần cân bằng giữa tính chính xác và tính sáng tạo.

NEXT TOKEN PREDICTION CAPABILITY ZONE



- Những nhiệm vụ mà mô hình đã gặp vô số lần trong quá trình huấn luyện thuộc về vùng năng lực (Capability Zone). Ví dụ:Tóm tắt văn bản, chuyển đổi định dạng nội dung, giải thích các khái niệm phổ biến, soạn thảo theo một phong cách quen thuộc
- Trong các trường hợp này, cơ chế dự đoán token tiếp theo hoạt động rất hiệu quả vì các mẫu dữ liệu rất dày đặc và nhất quán.

NEXT TOKEN PREDICTION LIMITATION ZONE

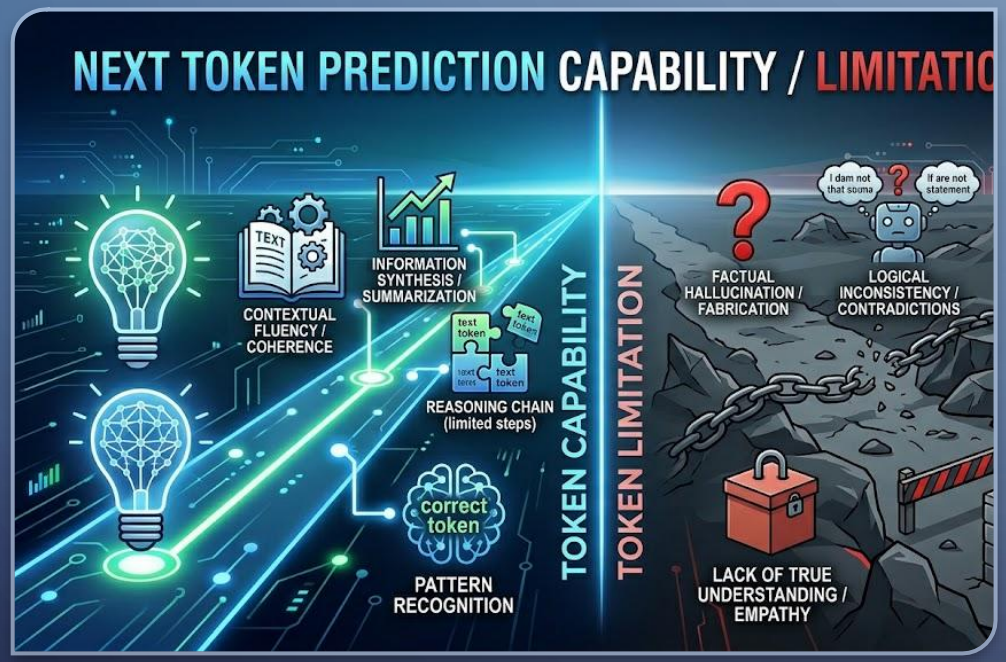


- Càng tiến vào những khu vực ít quen thuộc hơn:
  - Chủ đề mới lạ
  - Kiến thức quá chuyên sâu
  - Thông tin hiếm gặp
  - Những trường hợp đặc biệt
- Các mẫu dữ liệu mà AI dựa vào sẽ trở nên thưa thớt hơn.
- AI vẫn tiếp tục tạo văn bản một cách lưu loát
- Nhưng kết quả trả về có thể không chính xác (hiện tượng ảo giác)

ĐIỂM MẠNH VÀ ĐIỂM YẾU XUẤT PHÁT TỪ CÙNG MỘT CƠ CHẾ

- Điểm mạnh lớn nhất và điểm yếu lớn nhất của AI đều xuất phát từ cơ chế dự đoán token tiếp theo.
- Điểm mạnh: Khả năng tạo ra văn bản tự nhiên, trôi chảy và phù hợp ngữ cảnh đến từ cơ chế này.
- Điểm yếu: Hiện tượng "ảo giác AI" (hallucination)
- Ta sẽ gặp mặt nào của AI phụ thuộc vào vị trí nhiệm vụ giao cho AI nằm trên phổ từ quen thuộc hay xa lạ.

VÍ DỤ NEXT TOKEN PREDICTION CAPABILITY ZONE – LIMITATION ZONE



- **Capability zone:** Khi yêu cầu AI tóm tắt lập luận trong một bài luận, AI nhanh chóng tạo ra một đoạn văn rõ ràng, mạch lạc và dễ hiểu. Mô hình đã gặp hàng nghìn, thậm chí hàng triệu ví dụ tương tự trong quá trình huấn luyện.
- **Limitation zone:** Khi yêu cầu AI liệt kê ba bài báo nghiên cứu của một nhà nghiên cứu tầm trung trong một chuyên ngành rất hẹp, kèm theo năm xuất bản. AI vẫn trả lời với giọng điệu tự tin.Vẫn viết rất trôi chảy. Nhưng lần này "con đường" mà mô hình phải đi không còn quen thuộc nữa. Mô hình đang tạo ra thứ trông giống như một câu trả lời tốt. Một số bài báo có thể là thật. Một số khác có thể hoàn toàn do AI tự tạo ra.

KHI SỬ DỤNG AI, HÃY GHI NHỚ NHỮNG ĐIỀU SAU

Giọng điệu tự tin không đồng nghĩa với độ chính xác

Thông tin càng cụ thể càng cần kiểm chứng

Hãy xem đầu ra của AI như một bản nháp

Hãy tự hỏi nhiệm vụ của giao cho AI nằm ở đâu trên phổ năng lực

Tận dụng các công cụ hỗ trợ kiểm chứng

THÔNG TIN CÀNG CỤ THỂ CÀNG CẦN KIỂM CHỨNG

- Những nội dung dễ bị AI bịa đặt nhất thường là:
  - Tên người
  - Ngày tháng
  - Số liệu thống kê
  - Trích dẫn
  - Câu nói nguyên văn
  - URL
  - Tài liệu tham khảo
- Thông tin càng chi tiết và cụ thể thì càng cần được kiểm tra lại.

HÃY XEM ĐẦU RA CỦA AI NHƯ MỘT BẢN NHÁP

- Đặc biệt trong những trường hợp:
  - Công việc quan trọng
  - Lĩnh vực bạn chưa quen thuộc
  - Các quyết định có ảnh hưởng lớn
- Bạn nên coi câu trả lời của AI là một bản nháp cần được xác minh thay vì sự thật tuyệt đối.

HÃY TỰ HỎI NHIỆM VỤ GIAO CHO AI NẰM Ở ĐÂU TRÊN PHỔ NĂNG LỰC

Nếu nhiệm vụ thuộc nhóm quen thuộc và phổ biến:

- AI thường đáng tin cậy hơn.
- Có thể giao nhiều việc hơn cho AI.

Nếu nhiệm vụ thuộc nhóm hiếm gặp hoặc chuyên sâu:

- Cần kiểm tra kỹ hơn.
- Cần dành nhiều sự giám sát hơn.

TẬN DỤNG CÁC CÔNG CỤ HỖ TRỢ KIỂM CHỨNG

- Nếu hệ thống AI cung cấp:
  - Trích dẫn nguồn
  - Liên kết tham khảo
  - Dẫn chứng cụ thể
- Hãy sử dụng chúng.
- Mô hình AI không thể luôn phân biệt chính xác đâu là thông tin có căn cứ và đâu là thông tin do nó tự tạo ra.
- Phần đánh giá cuối cùng vẫn thuộc về người dùng.

CÁC CÔNG TY AI ĐÃ LÀM GÌ ĐỂ KHẮC PHỤC?

- Trích dẫn nguồn và liên kết nguồn gốc (Source Grounding): cho phép người dùng kiểm tra thông tin nào được hỗ trợ bởi nguồn thực tế và thông tin nào chỉ được AI tạo ra.
- Thể hiện sự không chắc chắn: Ví dụ khi AI nói:"Tôi không chắc về thông tin này.“ Điều đó giúp mô hình cảnh báo người dùng rằng câu trả lời có thể không đáng tin cậy.
- Tạo sinh có ràng buộc (Constrained Generation): giới hạn không gian tạo sinh để giảm khả năng xuất hiện thông tin bịa đặt.
- Vòng lặp Sinh – Kiểm tra (Generator–Verifier Loop): một hệ thống khác sẽ kiểm tra lại kết quả từ AI bằng các nguồn bên ngoài trước khi xuất ra cho người dùng.



MẶT MẠNH CỦA NEXT TOKEN PREDICTION

- Viết trôi chảy trong nhiều phong cách khác nhau.
- Tổng hợp thông tin nhanh chóng từ nhiều lĩnh vực.
- Thực hiện tốt các nhiệm vụ tương tự những gì đã được học trước đây.
- Tiếp tục mạch hội thoại một cách nhất quán.

MẶT YẾU CỦA NEXT TOKEN PREDICTION

- Hallucination (bịa đặt thông tin)
- Thiếu nhất quán (phụ thuộc các phương pháp sampling)
- Thể hiện sự tự tin không đúng mức

KẾT LUẬN
NEXT TOKEN PREDICTION

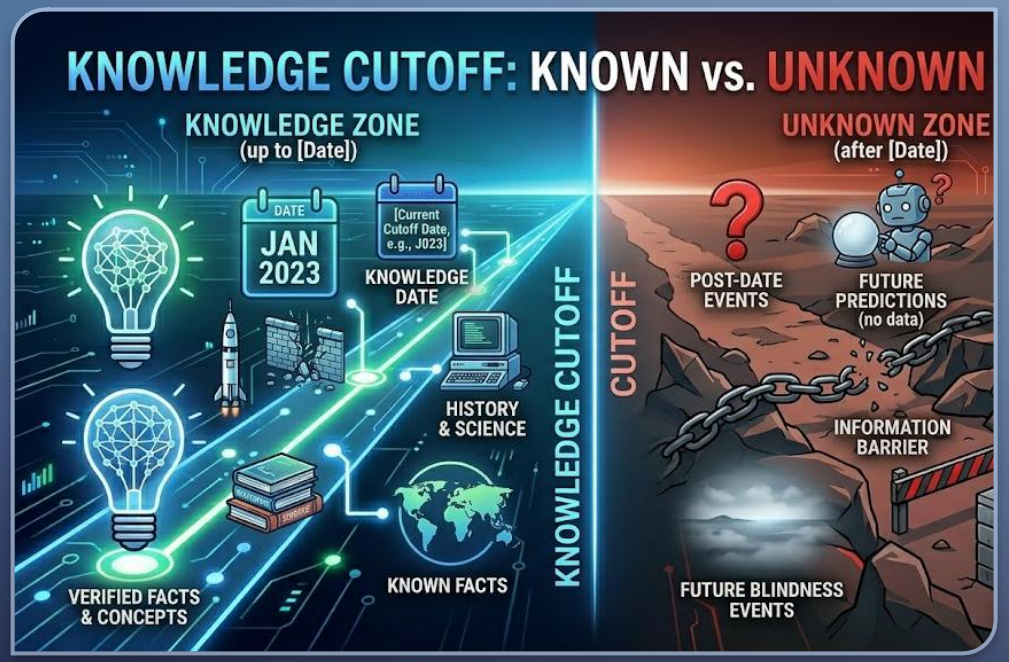
- Mọi câu trả lời của AI đều được tạo ra bằng cách dự đoán những từ có khả năng xuất hiện tiếp theo
- Điều này giải thích tại sao AI vừa có thể: Viết rất tự nhiên, tổng hợp thông tin rất tốt, hỗ trợ nhiều loại công việc khác nhau.
- Nhưng đồng thời cũng có thể: bịa đặt thông tin, trả lời thiếu nhất quán, thể hiện sự tự tin không tương xứng với độ chính xác.
- Khi hiểu được điều này, AI sẽ trở thành một công cụ dễ dự đoán và dễ kiểm soát hơn.
- Next Token Prediction là nền tảng của khả năng discernment.

AI KNOWNLEDGE



- Các mô hình AI học bằng cách đọc một lượng văn bản khổng lồ từ Internet, các bộ dữ liệu công khai và nhiều nguồn tài liệu viết khác.
- Thông qua hàng tỷ lần lặp của câu hỏi: "Dựa trên tất cả những gì đã có trước đó, điều gì sẽ xuất hiện tiếp theo?“
- Mô hình xây dựng các biểu diễn nội bộ về khái niệm, mối quan hệ và sự kiện.
- Đó là cách AI biết mọi thứ. Và cũng là cách duy nhất nó biết mọi thứ.

KNOWLEDGE CUTOFF



- Mô hình không có trải nghiệm thực tế. Nó không duyệt web theo thời gian thực, trừ khi sản phẩm được trang bị công cụ tìm kiếm.
- Thời điểm quá trình huấn luyện kết thúc được gọi là Knowledge Cutoff (mốc cắt kiến thức).
- Mọi thứ xảy ra sau thời điểm đó không tồn tại trong kiến thức của mô hình.

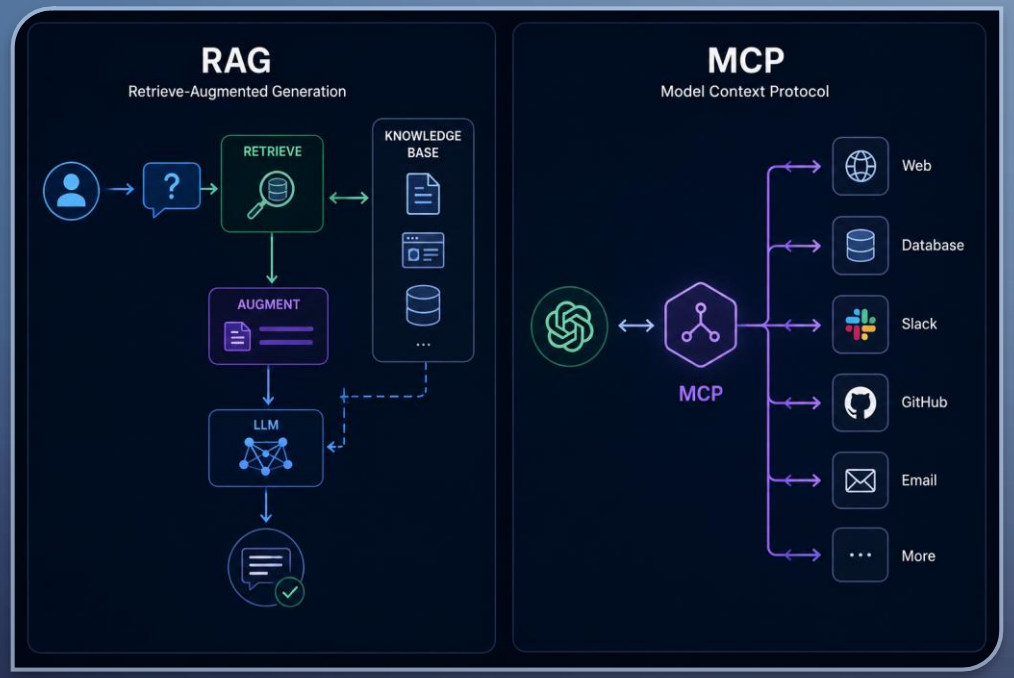
KNOWLEDGE CUTOFF VÍ DỤ

- Capability zone: khi hỏi AI “Hãy giải thích quá trình quang hợp hoạt động như thế nào”. Ta nhận được câu trả lời chi tiết, chính xác. Đây là chủ đề đã xuất hiện hàng nghìn lần trong dữ liệu huấn luyện, được mô tả nhất quán và không thay đổi theo thời gian.
- Limitation zone: Khi hỏi AI “Ai là bí thư thành phố Hà Nội hiện tại?” Mô hình có thể đưa ra một cái tên. Nó có thể đúng hoặc đó có thể là người giữ chức vụ đó cách đây một năm.

CAPABILITY ZONE VS LIMITATION ZONE

- Capability Zone: Khoa học phổ thông, Ngôn ngữ lập trình phổ biến, Lịch sử được ghi chép đầy đủ. Những chủ đề xuất hiện thường xuyên, nhất quán và trước mốc cắt kiến thức. Trong khu vực này, năng lực của mô hình cực kỳ sâu rộng.
- Limitation zone: chủ đề hiếm gặp, sự kiện xảy ra sau mốc cắt kiến thức, lĩnh vực chuyên môn hẹp, kiến thức địa phương. Trong khu vực này, năng lực mô hình sẽ bị hạn chế

GIẢI PHÁP KHẮC PHỤC KNOWLEDGE CUTOFF



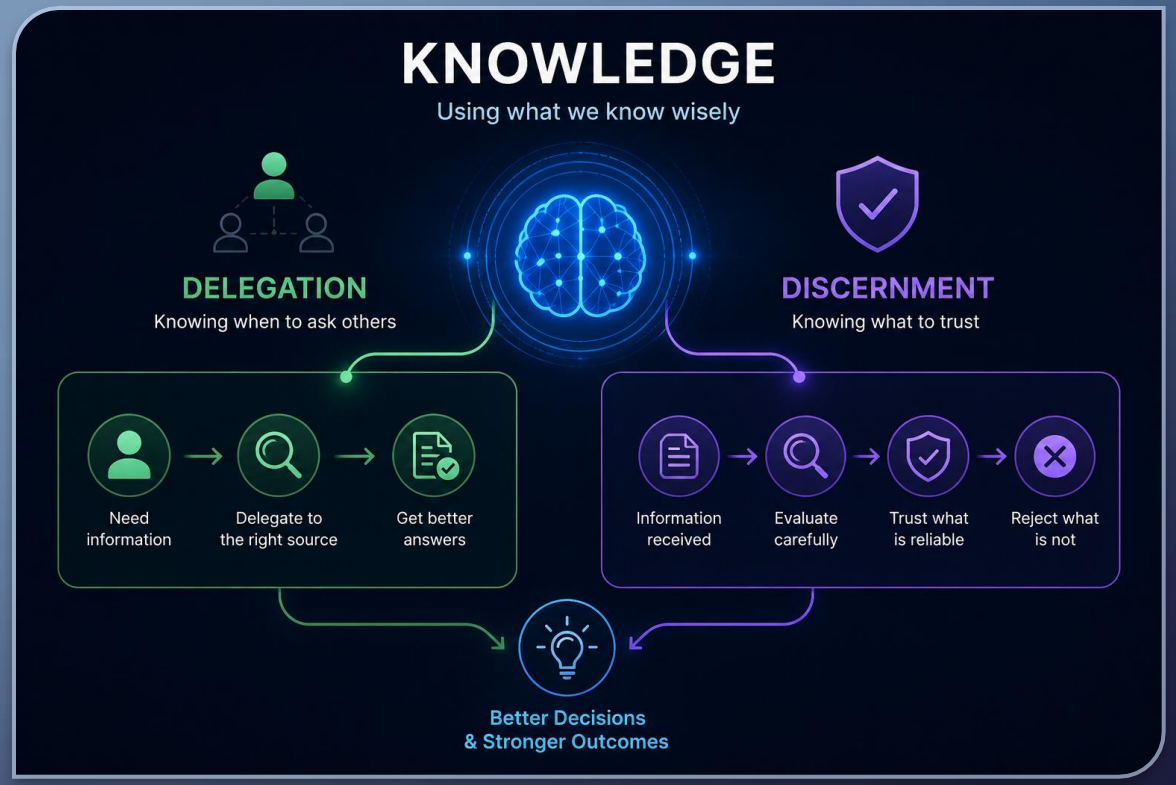
- Tích hợp AI với việc tìm kiếm thông tin trên internet để cập nhật thông tin mới
- Sử dụng kỹ thuật RAG hoặc MCP. RAG/MCPs giúp kết nối mô hình với những tài liệu mà nó chưa từng được huấn luyện trên đó, chẳng hạn như wiki nội bộ của công ty hoặc cơ sở dữ liệu chuyên ngành.

LƯU Ý

- Hãy kiểm chứng mọi thông tin phụ thuộc thời gian.
- Luôn giả định rằng mô hình có thể đang sử dụng dữ liệu cũ.
- Hãy thử nghiệm trước khi tin tưởng AI trong một lĩnh vực mới.
- Việc AI rất giỏi ở một lĩnh vực không có nghĩa là nó cũng giỏi ở lĩnh vực kế bên.
- Hãy chú ý tới các giả định mặc định có thể phản ánh dữ liệu huấn luyện hơn là thực tế.

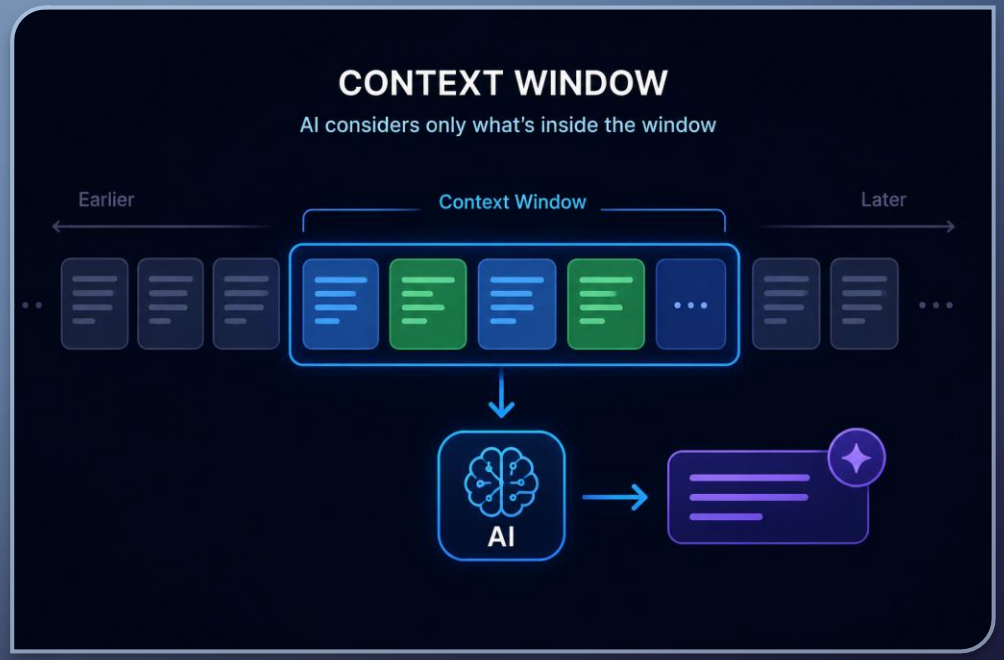
KNOWNLEDGE VỚI 4DS

- Hiểu được đặc tính kiến thức của AI ảnh hưởng trực tiếp đến hai năng lực quan trọng trong việc sử dụng AI.
- Delegation: trước khi giao một nhiệm vụ cho AI, hãy tự hỏi: Đây có phải là lĩnh vực mà mô hình hiểu rõ hay không? Hay ta cần cung cấp thêm kiến thức thông qua ngữ cảnh, tài liệu hoặc công cụ tìm kiếm?
- Discernment: Khi nhận được câu trả lời, ta sẽ biết những thông tin nào cần được xác minh thêm (Các nội dung thuộc vùng limitation zone như: thông tin mới, chủ đề hiếm gặp hay kiến thức địa phương)



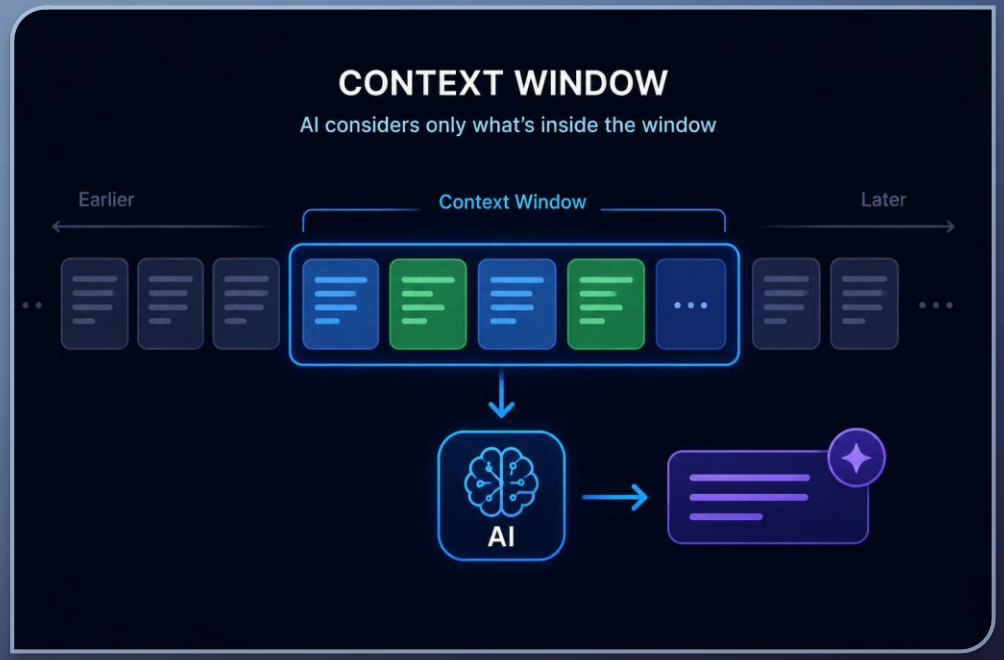
CONTEXT WINDOW (CỬA SỔ NGỮ CẢNH)

- Các chỉ dẫn (instructions) của bạn.
- Những câu trả lời trước đó của AI.
- Các tài liệu bạn tải lên.
- Toàn bộ cuộc hội thoại qua lại.
- Tất cả đều nằm trong một vùng chứa hữu hạn. Và mô hình chỉ có thể chú ý tới những gì đang nằm bên trong vùng chứa đó.



GIỚI HẠN CỦA CONTEXT WINDOW

- Khi cuộc hội thoại hoặc tập tài liệu vượt quá khả năng chứa của cửa sổ này, một phần thông tin sẽ bị loại bỏ.
- Phần bị loại bỏ thường là nội dung cũ nhất.
- Việc này thường diễn ra âm thầm. AI sẽ không dừng lại và thông báo: "Tôi vừa quên ba tin nhắn đầu tiên của bạn.“ Nó chỉ tiếp tục làm việc với những gì còn lại trong cửa sổ ngữ cảnh.



CONTEXT WINDOW

- Theo mặc định, cửa sổ ngữ cảnh sẽ được làm trống giữa các phiên làm việc.
- Ví dụ: Hôm nay bạn trò chuyện với AI. Ngày mai bạn mở một cuộc trò chuyện mới. Bạn đang bắt đầu từ con số 0 .Cuộc hội thoại hôm qua đã biến mất.
- Các ứng dụng AI hiện nay sử dụng các kỹ thuật như: Memory (Bộ nhớ), file.md, Hồ sơ người dùng, các cơ chế lưu trữ ngữ cảnh khác để chủ động mang các thông tin cần thiết vào cửa sổ ngữ cảnh đang làm việc.

CONTEXT WINDOW
CAPABILITY ZONE AND LIMITATION ZONE

Capability zone: Khi toàn bộ dữ liệu/thông tin cần thiết đều có trong cửa sổ ngữ cảnh. AI sẽ làm việc hiểu quả

Limitation zone: Tài liệu hay cuộc hội thoại càng dài, AI sẽ tiến vào limitation zone. Khác với Khả năng dự đoán token tiếp theo hay Kiến thức suy giảm từ từ khi tiến tới vùng limitation zone. Context window thường hoạt động tốt cho đến khi đột ngột không còn hoạt động tốt nữa.

TẠI SAO CONTEXT WINDOW LẠI CÓ GIỚI HẠN?

- Bởi vì mỗi lần tạo phản hồi, mô hình phải xử lý toàn bộ ngữ cảnh như một khối thống nhất. Nó cần đọc tất cả: tin nhắn, tài liệu, hướng dẫn từ đầu đến cuối để quyết định nên tạo ra nội dung gì tiếp theo.
- Do đó luôn tồn tại một giới hạn về lượng thông tin mà mô hình có thể chứa mà vẫn đảm bảo tạo ra câu trả lời mạch lạc.

LOST IN THE MIDDLE EFFECT

- Ngay cả khi chưa chạm tới giới hạn đó, sự chú ý của mô hình cũng không phân bố hoàn toàn đồng đều.
- Các nghiên cứu về ngữ cảnh dài đã phát hiện hiện tượng gọi là: Lost in the Middle Effect (Hiệu ứng mất thông tin ở giữa).
- Những thông tin nằm sâu ở giữa một tài liệu hoặc cuộc hội thoại rất dài thường có ảnh hưởng yếu hơn so với: thông tin ở đầu hay thông tin ở cuối.

KHI CỬA SỔ NGỮ CẢNH ĐẦY

Quên nội dung ở đầu cuộc trò chuyện.

Nhớ mơ hồ các nội dung ở giữa.

Bỏ sót các chi tiết quan trọng.

GIẢI PHÁP HIỆN NAY

Memory: Lưu các thông tin quan trọng giữa các phiên làm việc.

Compaction / Summarization: Tự động tóm tắt lịch sử hội thoại để giải phóng không gian khi cuộc trò chuyện quá dài.

Projects và Workspaces: Giữ các tài liệu nền luôn nằm trong ngữ cảnh mà không cần tải lên lại.

Skills: Chỉ kích hoạt các chỉ dẫn khi nhiệm vụ cụ thể cần đến chúng.

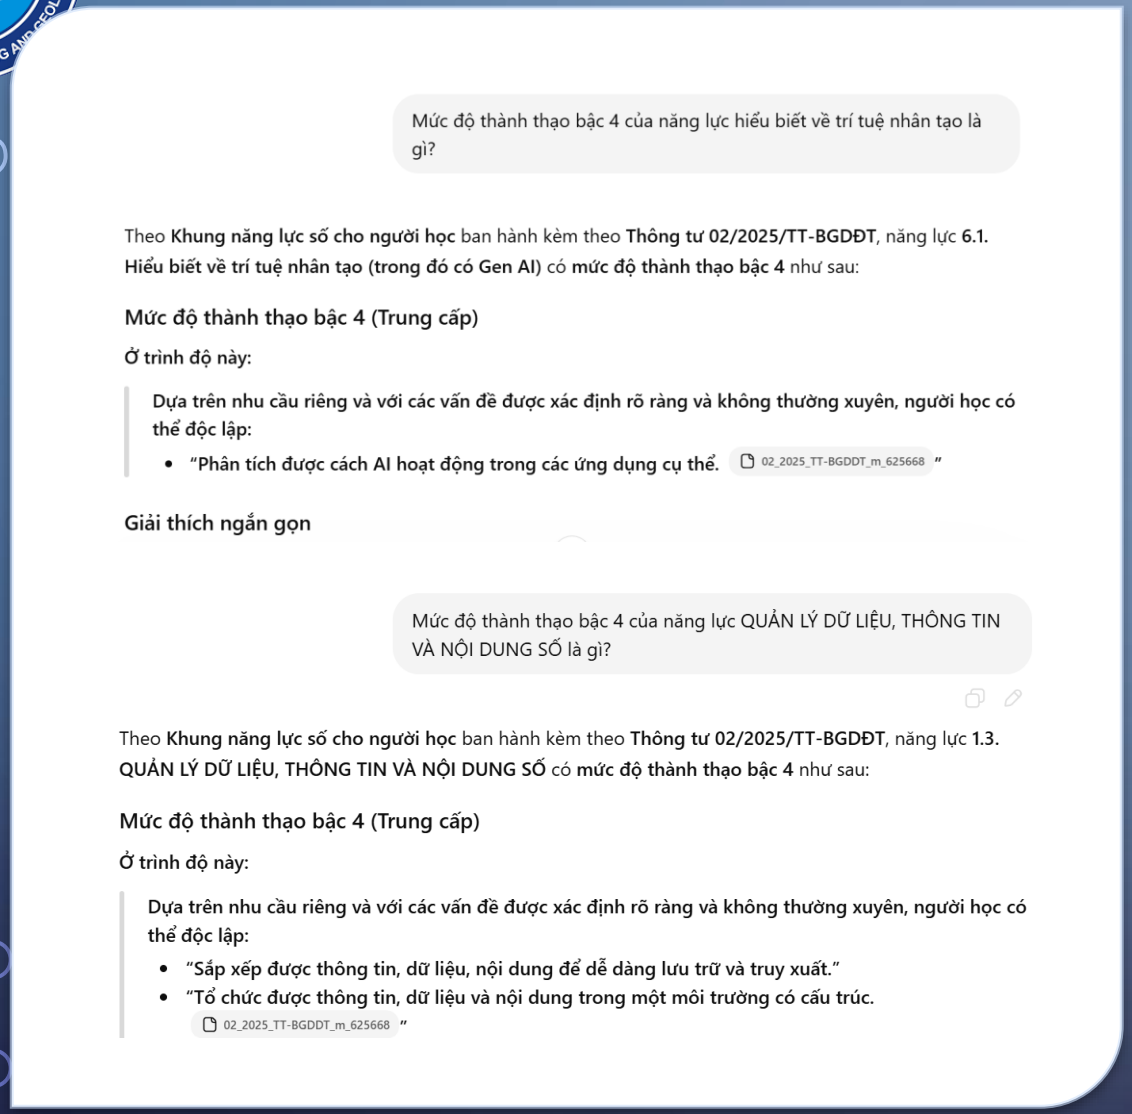
DẤU HIỆU KHÍ CONTEXT WINDOW ĐẾN GIỚI HẠN

Cuộc hội thoại đã rất dài và chất lượng bắt đầu giảm.

Bạn tải lên tài liệu rất dài và nhận thấy các chi tiết ở giữa tài liệu không còn xuất hiện trong câu trả lời.

MỘT SỐ GIẢI PHÁP KHÁC PHỤC KHÁC

- **Đưa thông tin quan trọng lên đầu:** Đối với tài liệu dài, đừng chôn thông tin quan trọng ở trang 42. Hãy đặt nó gần đầu tài liệu.
- **Chia nhỏ công việc:** Thay vì tải lên một tài liệu khổng lồ, hãy xử lý từng phần.
- **Sử dụng các tính năng lưu ngữ cảnh:** Projects, Skills hay Memory để giữ lại các thông tin nền thường dùng.
- **Bắt đầu cuộc trò chuyện mới khi chất lượng giảm:** nếu AI bắt đầu trả lời kém sau một cuộc hội thoại dài, hãy tạo cuộc trò chuyện mới. Thông thường đó là vấn đề về giới hạn ngữ cảnh chứ không phải do AI mất năng lực. Một cuộc trò chuyện mới kèm theo bản tóm tắt ngắn gọn thường cho kết quả tốt hơn việc cố tiếp tục cuộc trò chuyện quá dài.

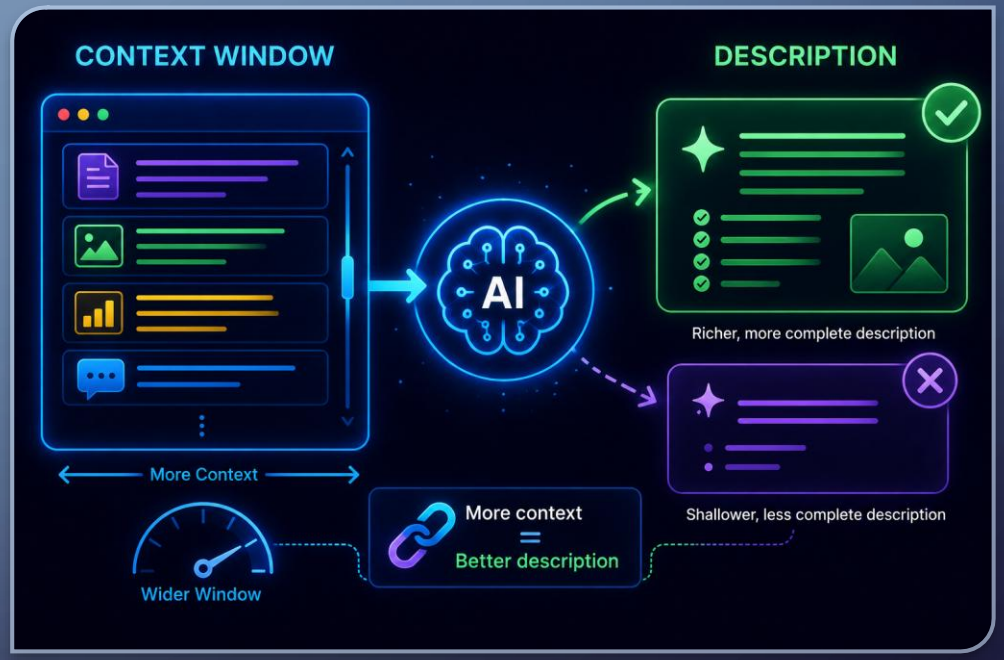


ĐƯA THÔNG TIN QUAN TRỌNG LÊN ĐẦU

- Cho GPT đọc tài liệu về TT02 dài 47 trang.
- Khi hỏi về mức độ thành thạo bậc 4 của năng lực hiểu biết về TTNT, GPT trả lời thiếu 1 ý (việc này xảy ra ngẫu nhiên), có lúc GPT vẫn trả lời đúng
- Khi hỏi về mức độ thành thạo bậc 4 của năng lực Quản lý dữ liệu, thông tin và nội dung số, GPT trả lời chính xác

CONTEXT WINDOW VÀ 4DS

- Hiểu cách hoạt động của cửa sổ sẽ cho bạn biết cách cấu trúc ngữ cảnh, khi nào nên ưu tiên xử lý thông tin trước và khi nào nên bắt đầu lại từ đầu.
- Hiểu được kích thước cửa sổ ngữ cảnh, các giới hạn của nó và cách nó được làm mới giữa các phiên, sẽ giúp ta biết cách viết prompt hiệu quả hơn; Khi nào cần nhắc lại thông tin quan trọng; Nội dung nào nên tải lên; Nội dung nào có thể lược bỏ.
- Đây là một trong những kiến thức quan trọng để làm việc hiệu quả với các hệ thống AI hiện đại.



KHẢ NĂNG ĐIỀU KHIỂN AI (STEERABILITY)



Steerability là khả năng của mô hình trong việc làm theo chỉ dẫn.



Vi dụ: “Yêu cầu AI trả lời dưới dạng bảng.“ -> AI trả về bảng.



"Hãy viết từ góc nhìn của một người hoài nghi.“ -> AI thay đổi góc nhìn.

STEERABILITY – FINE-TUNNING

Khả năng điều khiển xuất hiện nhờ quá trình Fine-tuning

Chính ở giai đoạn này mô hình học được cách

- Xem văn bản của như một yêu cầu
- Chia nhỏ nhiệm vụ thành các bước
- Tuân theo các quy tắc đặt ra

LIMITATION ZONE

- Tuy nhiên Khả năng làm theo chỉ dẫn không đồng nghĩa với việc hiểu đúng ý định của người dùng.
- Mô hình vẫn thực hiện chỉ dẫn thông qua cùng cơ chế hoàn thành mẫu (pattern completion) mà nó sử dụng cho mọi nhiệm vụ khác.
- Luôn tồn tại một khoảng cách giữa:
  - Những gì bạn gõ ra.
  - Điều bạn thực sự muốn.

LIMITATION ZONE

- Yêu cầu AI thực hiện "Hãy tóm tắt báo cáo này trong dưới 100 từ và viết thật mạnh mẽ.“ AI trả về kết quả dưới 100 từ với văn phong mạnh mẽ -> yêu cầu đã được thực hiện chính xác.
- Nhưng có thể thông tin quan trọng nhất trong báo cáo lại là một kết luận có điều kiện và khá dài dòng.
- Để làm cho bản tóm tắt ngắn gọn và mạnh mẽ hơn, AI đã loại bỏ phần đó.
- Kết quả: AI làm đúng điều người dùng yêu cầu, nhưng bỏ lỡ điều người dùng thực sự muốn.